Прогнозирование оттока клиентов телеком-компании

Telco Customer Churn Prediction

От SQL и EDA до XGBoost + SHAP: полный end-to-end ML-кейс

Киселев Артём — Junior Data Analyst
Date: 04/2026
GitHub: Tema Kiselev (temakiselevv) | Telegram: @tema_kiselev

PostgreSQL

Python

XGBoost

SHAP

Docker

Бизнес-задача и цель проекта

26.5%

текущий отток клиентов

Проблема

Клиенты уходят — снижается выручка

Удержать клиента дешевле, чем привлечь нового

Цель проекта

Предсказать клиентов с риском оттока

Объяснить — почему уходят (SHAP-инсайты)

Ожидаемый бизнес-результат

Потенциальное снижение оттока за счёт внедрения таргетированных retention-кампаний

Ограничения проекта

Статические данные

Срез на момент выгрузки — без истории изменений поведения клиентов.

Нет A/B-тестов

Рекомендации требуют дополнительной валидации перед запуском.

Переобучение модели

Поведение клиентов меняется — необходим плановый ретрейн (раз в квартал).

Данные и предобработка (SQL-пайплайн)

Источник
Telco Customer Churn (Kaggle)

Объём
7 043 клиента

Признаки
21 исходный признак

CSV → raw schema → clean schema → main view → Python (pandas)

SQL-шаги:

- Импорт CSV → таблица raw.wa_fn_usec
- Очистка: NULL в TotalCharges → 0
- Создание новых флагов рискованных категорий
- Создание аналитической витрины clean.vw_churn_analysis

Python (pandas):

- Конвертация типов данных
- Кодирование Yes/No → 0/1
- Создание новых флагов рискованных категорий

Исследовательский анализ данных (EDA) — ключевые выводы

26.54%	42.7%	45.3%	53.3%
общий отток	отток помесячный контракт	отток Electronic check	отток новые клиенты (1-6 мес.)

Ключевые инсайты

- Клиенты с помесячным контрактом уходят в 3.5 раз чаще, чем с долгосрочным.
- Высокие платежи + первые 6 месяцев — максимальный риск: до 77.5% оттока
- Пол клиента практически не влияет (разница ±0.76%)
- tenure: корреляция с оттоком −0.35 | MonthlyCharges: +0.19

Исследовательский анализ данных (EDA) — ключевые выводы

26.54%	42.7%	45.3%	53.3%
общий отток	отток помесячный контракт	отток Electronic check	отток новые клиенты (1-6 мес.)

Распределение оттока клиентов (Churn)

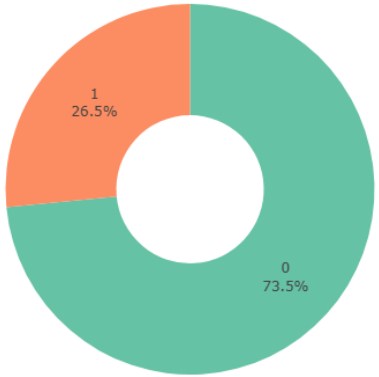

Процент оттока (Churn = 1) по Contract

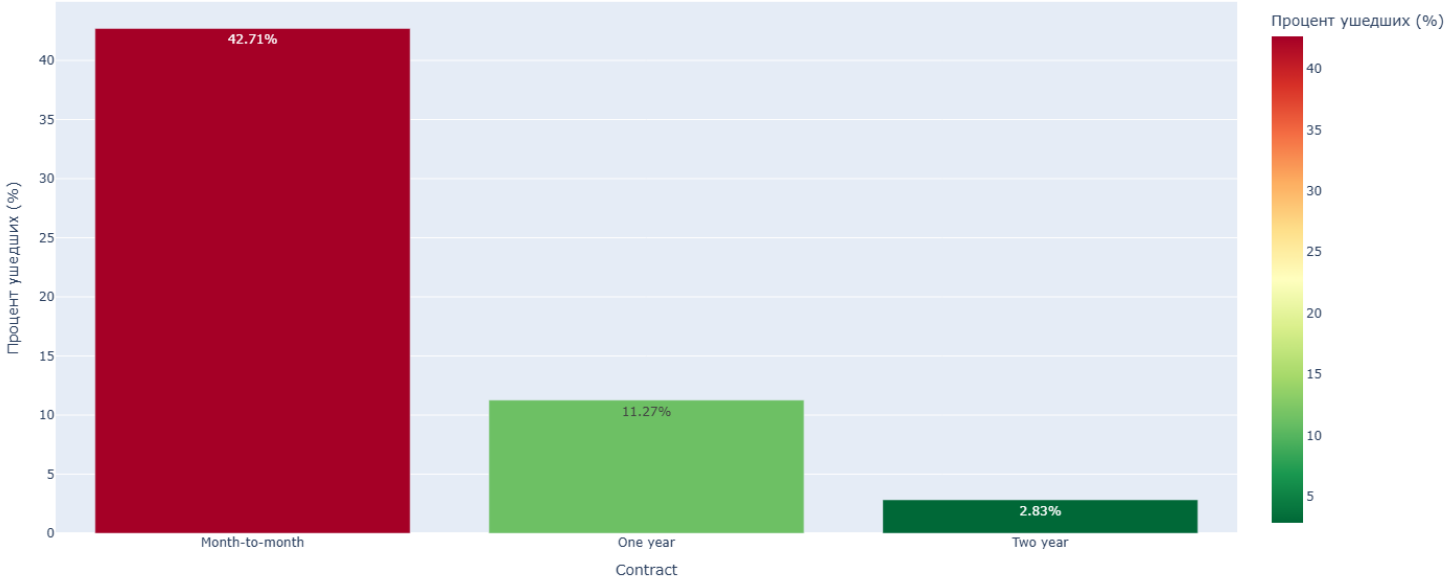

Исследовательский анализ данных (EDA) — ключевые выводы

26.54%	42.7%	45.3%	53.3%
общий отток	отток помесячный контракт	отток Electronic check	отток новые клиенты (1-6 мес.)

ТОП-10 самых рискованных категориальных признаков

	category	value	churn_rate
0	tenure_group	1-6 months	53.33%
1	PaymentMethod	Electronic check	45.29%
2	Contract	Month-to-month	42.71%
3	InternetService	Fiber optic	41.89%
4	OnlineSecurity	No	41.77%
5	SeniorCitizen	1.0	41.68%
6	TechSupport	No	41.64%
7	OnlineBackup	No	39.93%
8	DeviceProtection	No	39.13%
9	tenure_group	7-12 months	35.89%

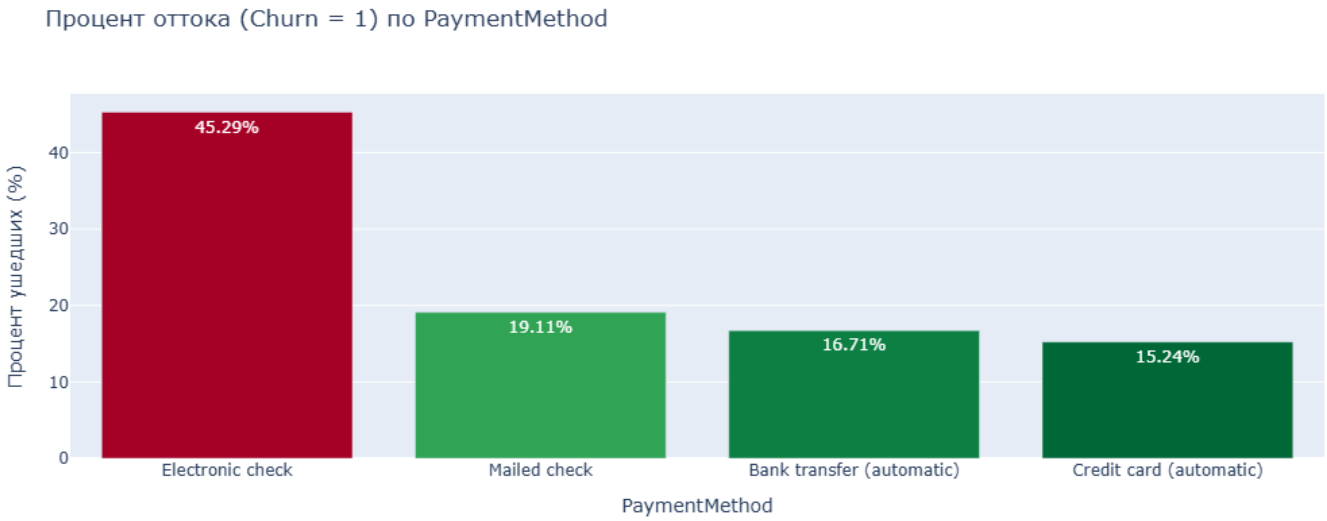

Исследовательский анализ данных (EDA) — ключевые выводы

26.54%
общий отток

42.7%
отток помесячный контракт

45.3%
отток Electronic check

53.3%
отток новые клиенты (1-6 мес.)

Статистические тесты влияния числовых признаков на отток

Признак	Mean (No Churn)	Mean (Yes Churn)	Разница средних	t-статистика	p-value (t-test)	Корреляция (Point-Biserial)	Сила связи	p-value (корр.)
tenure	37.57	17.98	-19.59	-34.8238	0.000000	-0.3522	средняя	0.000000
MonthlyCharges	61.27	74.44	13.18	18.4075	0.000000	0.1934	слабая	0.000000
TotalCharges	2549.91	1531.80	-1018.12	-18.7066	0.000000	-0.1983	слабая	0.000000

Процент оттока (Churn = 1) по tenure_group

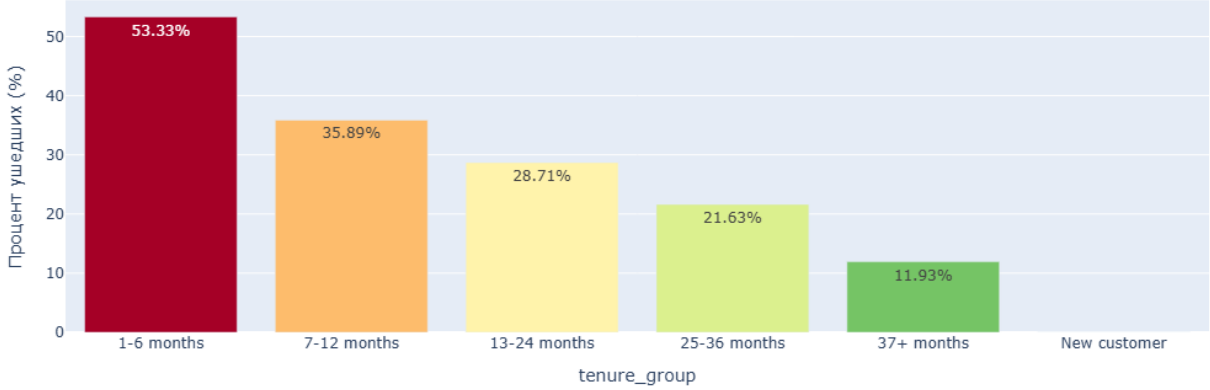

Feature Engineering — усиление модели

Цель: помочь модели выявлять сложные взаимодействия признаков и приблизить признаки к бизнес-логике поведения клиента

Признак	Логика создания
avg_monthly_per_tenure_month	Средний чек за месяц пользования — сильный предиктор
high_risk_combination	Комбо: короткий стаж + высокий платёж + нет поддержки (топ-3)
num_additional_services	Количество дополнительных услуг клиента
month_to_month_flag	Флаг помесячного контракта
electronic_check_flag	Флаг оплаты электронным чеком

Feature Engineering — усиление модели

Первые 5 строк новых признаков

customerID	avg_monthly_per_tenure_month	num_additional_services	has_additional_services	high_monthly_flag	fiber_optic_flag	electronic_check_flag	month_to_month_flag	senior_citizen_flag	high_risk_combination
7639-LIAYI	1.53	4	1	0	0	0	0	0	0
9803-FTJCG	0.94	3	1	0	0	0	0	0	0
5160-UXJED	2.62	0	0	0	0	0	0	0	0
6122-EFVKN	1.49	2	1	0	0	0	0	0	0
3583-EKAPL	55.00	1	1	0	0	1	1	0	1

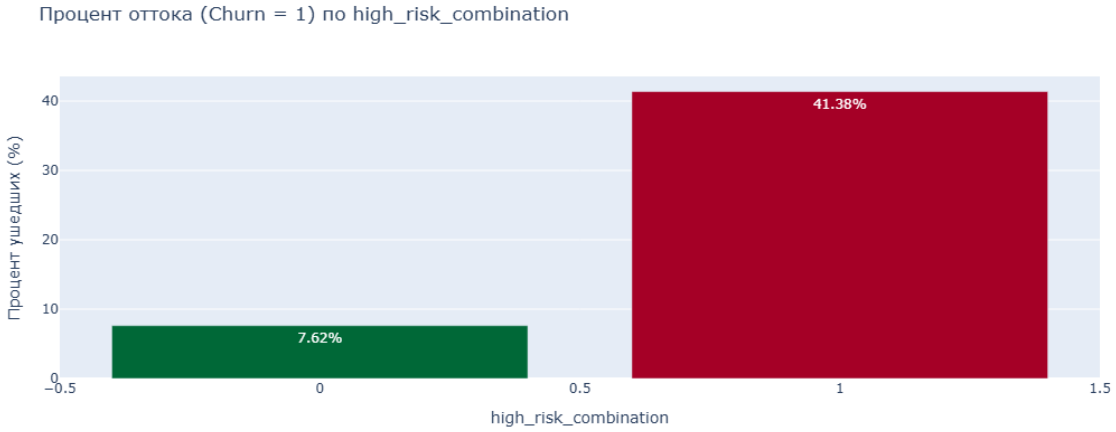

Логика создания признака «high_risk_combination»

```
df['high_risk_combination'] = (
    ((df['tenure_group'] == '1-6 months') & (df['high_monthly_flag'] == 1)) |
    ((df['tenure_group'] == '7-12 months') & (df['high_monthly_flag'] == 1)) |
    ((df['tenure_group'] == '1-6 months') & (df['fiber_optic_flag'] == 1)) |
    ((df['tenure_group'] == '1-6 months') & (df['senior_citizen_flag'] == 1)) |
    ((df['tenure_group'] == '1-6 months') & (df['electronic_check_flag'] == 1)) |
    ((df['tenure_group'] == '1-6 months') & (df['TechSupport'] == 'No')) |
    ((df['tenure_group'] == '1-6 months') & (df['OnlineSecurity'] == 'No')) |
    ((df['month_to_month_flag'] == 1) & (df['senior_citizen_flag'] == 1)) |
    ((df['month_to_month_flag'] == 1) & (df['fiber_optic_flag'] == 1)) |
    ((df['electronic_check_flag'] == 1) & (df['OnlineBackup'] == 'No')) |
    ((df['tenure_group'] == 1) & (df['electronic_check_flag'] == 1)) |
    ((df['electronic_check_flag'] == 1) & (df['high_monthly_flag'] == 1)) |
    ((df['fiber_optic_flag'] == 1) & (df['high_monthly_flag'] == 1))
).astype(int)
```

Моделирование и выбор лучшей модели

XGBoost
выбран как один из лучших алгоритмов для табличных данных

Train/Test split | StratifiedKFold | Bayesian Optimization | 25 итераций + 10 init

Порог	Accuracy	Precision	Recall	F1-score	ROC-AUC
0.5	0.7771	0.5584	0.7674	0.6464	0.8549
0.4632	**0.7715**	**0.5474**	**0.8021**	**0.6508**	**0.8549**

← *Оптимальный порог*

Почему оптимизировали Recall?

Бизнес-приоритет — не пропустить уходящего клиента. Ложное срабатывание (ненужное удержание) стоит дешевле, чем пропущенный отток. Порог снижен с 0.50 до 0.4632 — Recall вырос с 76.7% до 80.2% при минимальной потере Accuracy.

Моделирование и выбор лучшей модели

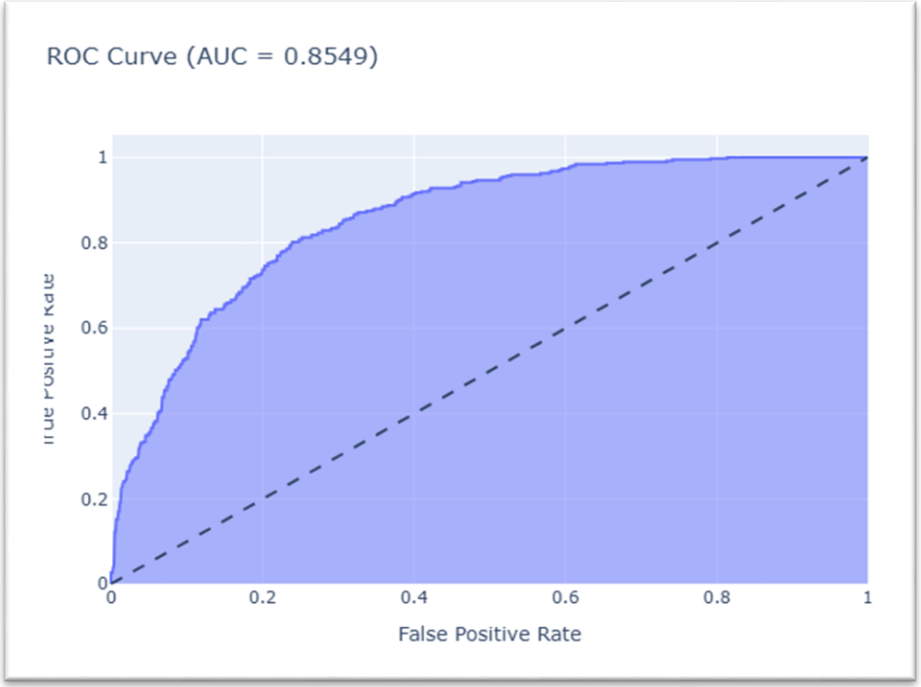

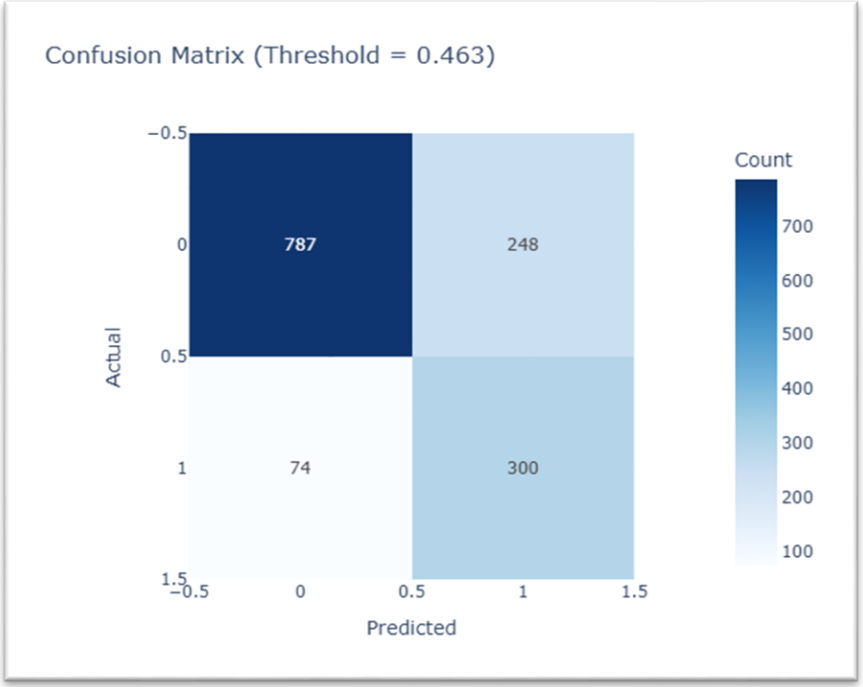

Интерпретация модели — SHAP (глобальная важность)

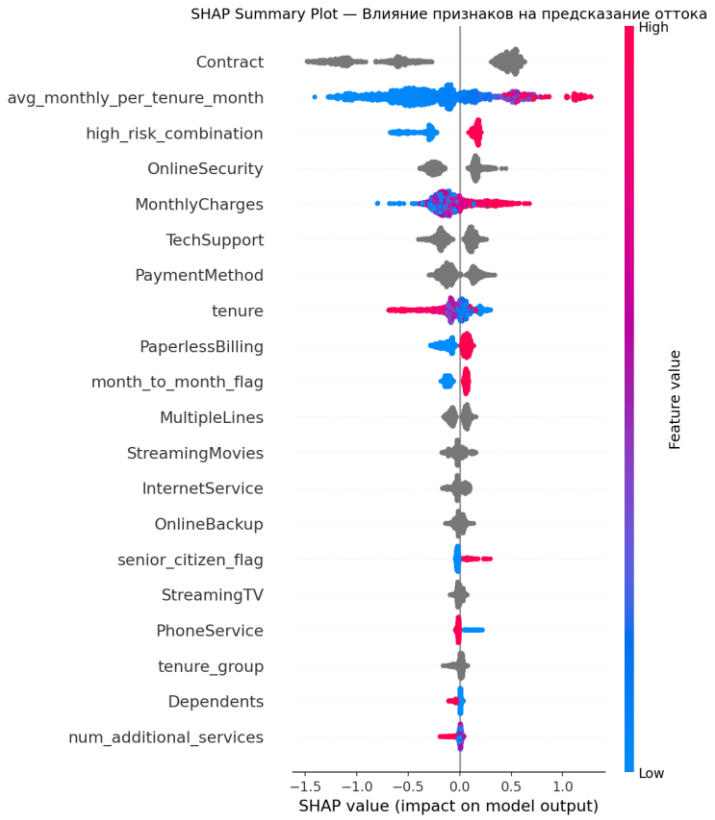

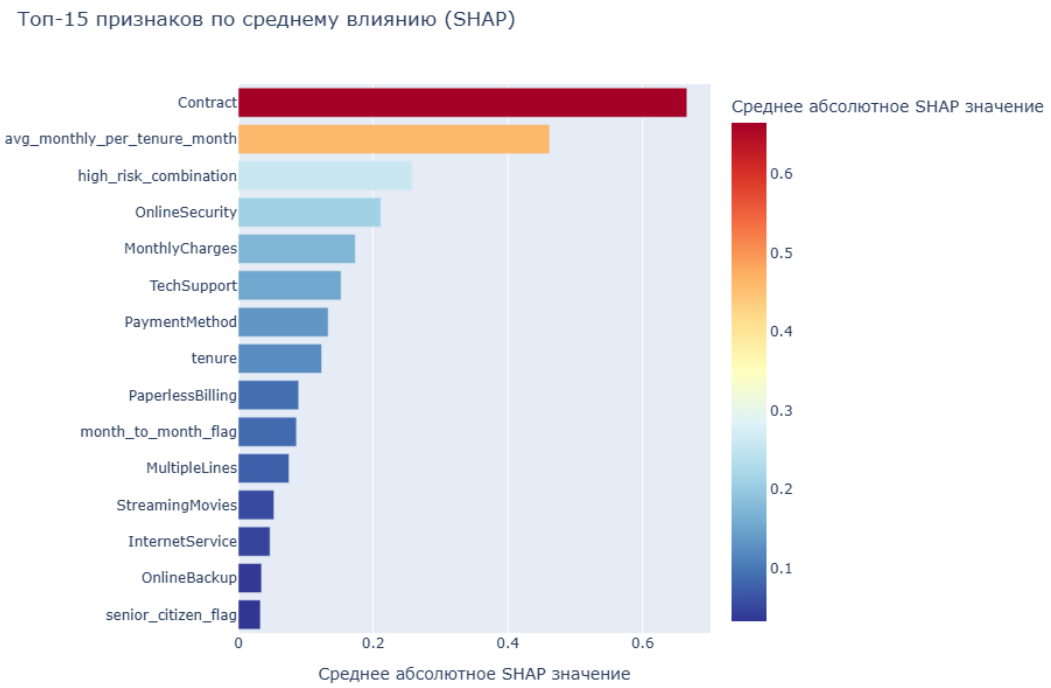

Бизнес-рекомендации на основе анализа и модели

1

Стимулировать переход на долгосрочный контракт

Скидка на годовой/двухгодовой контракт.
Потенциальный эффект: снижение оттока в сегменте month-to-month с 42% до 15%.

2

Продвижение дополнительных слуг (особенно техподдержки и онлайн-безопасности)

Особенно для новых клиентов с высокими платежами (первые 6 месяцев — критичный период).

3

Пересмотреть стратегию для Electronic check

Предложить альтернативные методы оплаты с бонусами.

Приоритизация:
сначала работать с top-risk сегментом (например, топ-10–20% клиентов по вероятности)

Результаты проекта и экономический эффект

Технические результаты

0.855	80.2%	0.651
ROC-AUC	Recall	F1-score

Модель интерпретируема (SHAP), готова к пилотному внедрению.

Оценочный бизнес-эффект

- Топ-20% рискованных → удержать каждого 4-го → −5% оттока
- LTV клиента ≈ 1 000 у.е., база 7 000 клиентов
- Доп. выручка ≈ 350 тыс. у.е./год
- Окупаемость < 3 месяцев

расчёт является приближённым и используется как иллюстрация потенциальной ценности модели

Дальнейшие шаги (Roadmap)

1 мес.

A/B-тест

Скидка на контракт vs бесплатная поддержка — сравнить удержание.

2 мес.

Деплой модели

FastAPI-сервис + обновление дашборда в реальном времени.

3 мес.

Внешние данные

Соцдем, жалобы в соцсетях → повышение качества предсказаний.

Q2+

Survival Analysis

Предсказание не только факта, но и времени до оттока.

Ongoing

Мониторинг

Дрейф данных + переобучение раз в квартал.

Заключение

Соединяя разведочный анализ, современное ML и интерпретируемый AI, построена модель, которая не только предсказывает отток, но и объясняет его причины. Это даёт бизнесу инструмент для точечного удержания клиентов и измеримой экономии.

Спасибо за внимание!

Контакты
GitHub: Tema Kiselev (temakiselevv) | **Telegram**: @tema_kiselev
Ссылка на репозиторий:
GitHub: github.com/temakiselevv/telco-churn-project